

# Relatório Técnico

## Aprendizado Supervisionado com Seleção de Features e Otimização de Hiperparâmetros

Gabriel Stiegemeier, Guilherme Einloft

<sup>1</sup>Universidade Federal de Santa Maria  
Santa Maria, RS, Brasil

{gstiegemeier, gmeinloft}@inf.ufsm.br

### 1. Introdução

O diabetes mellitus tipo 2 constitui uma das doenças crônicas de maior prevalência mundial, e sua detecção precoce é considerada um fator determinante para a redução de complicações clínicas a longo prazo. Nesse contexto, a aplicação de técnicas de aprendizado de máquina a dados clínicos apresenta potencial significativo para auxiliar no diagnóstico automatizado e na identificação de fatores de risco associados à doença.

O presente trabalho tem como objetivo o desenvolvimento de um pipeline completo de Machine Learning aplicado ao dataset *Pima Indians Diabetes*, originalmente coletado pelo National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK) e disponibilizado pelo UCI Machine Learning Repository. O dataset é composto por registros clínicos de mulheres da etnia Pima, com idade igual ou superior a 21 anos, e é amplamente utilizado como benchmark na literatura de classificação médica.

O pipeline abrange as seguintes etapas, conforme estipulado na especificação do trabalho:

1. **Análise exploratória** do dataset, incluindo diagnóstico de valores ausentes, outliers e distribuição de classes.
2. **Pré-processamento** dos dados, com imputação de valores ausentes, codificação de variáveis e escalonamento numérico.
3. **Seleção de features** por meio de Informação Mútua, complementada por análise de interpretabilidade via SHAP.
4. **Classificação binária** com Rede Neural Multicamadas (MLP), com comparação contra modelos clássicos (XGBoost e SVM).
5. **Classificação multiclasse** com MLP, utilizando limiares clínicos da American Diabetes Association (ADA) para categorização do nível glicêmico.
6. **Regressão** com MLP para predição da concentração de glicose plasmática.
7. **Otimização de hiperparâmetros** com o framework Optuna.
8. **Análise de overfitting** e avaliação de técnicas de regularização.

O dataset contém 768 amostras e 8 atributos preditivos numéricos, com a variável alvo de classificação binária indicando a presença (*Outcome* = 1) ou ausência (*Outcome* = 0) de diabetes. Para a tarefa de regressão, foi utilizada a variável *plas* (concentração de glicose plasmática em mg/dL) como alvo contínuo.

### 2. Metodologia

#### 2.1. Descrição do Dataset

O dataset *Pima Indians Diabetes* (OpenML id=37) possui as seguintes características:

- **Número de amostras:** 768
- **Número de atributos preditivos:** 8
- **Variável alvo (classificação binária):** `Outcome` — diagnóstico de diabetes (0 = negativo, 1 = positivo)
- **Variável alvo (regressão):** `plas` — concentração de glicose plasmática (mg/dL)

Os 8 atributos preditivos são:

| Atributo          | Descrição                                    |
|-------------------|----------------------------------------------|
| <code>preg</code> | Número de gestações                          |
| <code>plas</code> | Concentração de glicose plasmática (mg/dL)   |
| <code>pres</code> | Pressão arterial diastólica (mm Hg)          |
| <code>skin</code> | Espessura da dobra cutânea do tríceps (mm)   |
| <code>insu</code> | Insulina sérica ( $\mu$ U/mL)                |
| <code>mass</code> | Índice de massa corporal ( $\text{kg/m}^2$ ) |
| <code>pedi</code> | Função de pedigree de diabetes               |
| <code>age</code>  | Idade (anos)                                 |

### Distribuição das classes (classificação binária):

A classe negativa (0) corresponde a 500 amostras (65,1%) e a classe positiva (1) a 268 amostras (34,9%), resultando em uma razão de desbalanceamento de aproximadamente 0,54. Embora não se configure um desbalanceamento extremo, foi utilizado o parâmetro `class_weight="balanced"` nos modelos aplicáveis para mitigar qualquer viés em favor da classe majoritária.

#### 2.1.1. Problemas Identificados

**Valores ausentes codificados como zero:** Cinco atributos (`plas`, `pres`, `skin`, `insu` e `mass`) apresentaram valores zero biologicamente impossíveis. A coluna `insu` foi a mais afetada, com 48,7% de zeros inválidos, seguida por `skin` (29,6%), `plas` (0,7%), `pres` (4,6%) e `mass` (1,4%). Esses zeros foram tratados como valores ausentes.

**Outliers:** A análise por IQR identificou outliers em múltiplas variáveis, com destaque para `insu` (34 outliers), `pedi` (29 outliers) e `mass` (19 outliers). A análise complementar por Z-score ( $z > 3$ ) confirmou a presença de valores extremos nessas mesmas variáveis.

**Correlação entre atributos:** Nenhum par de features apresentou correlação superior a  $r = 0,7$ , o que indica ausência de multicolinearidade severa. As correlações mais relevantes observadas foram entre `skin` e `insu` ( $r = 0,44$ ) e entre `mass` e `skin` ( $r = 0,39$ ).

#### 2.2. Divisão Treino/Teste e Pré-processamento

O pré-processamento dos dados envolveu três operações principais: tratamento de valores ausentes, verificação de codificação de variáveis categóricas e escalonamento numérico. Para evitar o fenômeno de *data leakage* (vazamento de dados), o conjunto original foi inicialmente dividido em treino (80%, 614 amostras) e teste (20%, 154 amostras), com

estratificação pela variável alvo. Todas as operações de imputação e escalonamento foram ajustadas (fit) exclusivamente no conjunto de treino, sendo então aplicadas (transform) ao conjunto de teste.

### 2.2.1. Tratamento de Valores Ausentes — KNN Imputer (k=5)

Os zeros biologicamente inválidos nas colunas `plas`, `pres`, `skin`, `insu` e `mass` foram substituídos por NaN e, em seguida, imputados via KNN Imputer com k=5 vizinhos.

A escolha do KNN Imputer, em detrimento da imputação univariada simples (mediana ou média), foi motivada pela necessidade de preservar a estrutura multivariada dos dados. A imputação por mediana ignora as correlações entre os atributos: por exemplo, `skin` e `insu` possuem correlação positiva de  $r=0,44$  e `mass` e `skin` possuem  $r=0,39$ . Um valor imputado para `skin` deve, portanto, considerar as informações contidas em `insu` e `mass`.

O KNN Imputer utiliza os k vizinhos mais próximos, medidos pela distância euclidiana no espaço das features não ausentes, para estimar o valor faltante. O valor k=5 é um padrão robusto: suficientemente grande para suavizar o ruído, mas pequeno o bastante para capturar padrões locais nos dados.

Após a imputação, foi verificado que nenhum valor NaN remanescente existia no dataset (asserção programática: `nan_after == 0`).

## 3. Introdução

O diabetes mellitus tipo 2 constitui uma das doenças crônicas de maior prevalência mundial, e sua detecção precoce é considerada um fator determinante para a redução de complicações clínicas a longo prazo. Nesse contexto, a aplicação de técnicas de aprendizado de máquina a dados clínicos apresenta potencial significativo para auxiliar no diagnóstico automatizado e na identificação de fatores de risco associados à doença.

O presente trabalho tem como objetivo o desenvolvimento de um pipeline completo de Machine Learning aplicado ao dataset *Pima Indians Diabetes*, originalmente coletado pelo National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK) e disponibilizado pelo UCI Machine Learning Repository. O dataset é composto por registros clínicos de mulheres da etnia Pima, com idade igual ou superior a 21 anos, e é amplamente utilizado como benchmark na literatura de classificação médica.

O pipeline abrange as seguintes etapas, conforme estipulado na especificação do trabalho:

1. **Análise exploratória** do dataset, incluindo diagnóstico de valores ausentes, outliers e distribuição de classes.
2. **Pré-processamento** dos dados, com imputação de valores ausentes, codificação de variáveis e escalonamento numérico.
3. **Seleção de features** por meio de Informação Mútua, complementada por análise de interpretabilidade via SHAP.
4. **Classificação binária** com Rede Neural Multicamadas (MLP), com comparação contra modelos clássicos (XGBoost e SVM).
5. **Classificação multiclasse** com MLP, utilizando limiares clínicos da American Diabetes Association (ADA) para categorização do nível glicêmico.
6. **Regressão** com MLP para predição da concentração

de glicose plasmática. 7. **Otimização de hiperparâmetros** com o framework Optuna. 8. **Análise de overfitting** e avaliação de técnicas de regularização.

O dataset contém 768 amostras e 8 atributos preditivos numéricos, com a variável alvo de classificação binária indicando a presença (`Outcome = 1`) ou ausência (`Outcome = 0`) de diabetes. Para a tarefa de regressão, foi utilizada a variável `plas` (concentração de glicose plasmática em mg/dL) como alvo contínuo.

## 4. Metodologia

### 4.1. Descrição do Dataset

O dataset *Pima Indians Diabetes* (OpenML id=37) possui as seguintes características:

- **Número de amostras:** 768
- **Número de atributos preditivos:** 8
- **Variável alvo (classificação binária):** `Outcome` — diagnóstico de diabetes (0 = negativo, 1 = positivo)
- **Variável alvo (regressão):** `plas` — concentração de glicose plasmática (mg/dL)

Os 8 atributos preditivos são:

| Atributo          | Descrição                                    |
|-------------------|----------------------------------------------|
| <code>preg</code> | Número de gestações                          |
| <code>plas</code> | Concentração de glicose plasmática (mg/dL)   |
| <code>pres</code> | Pressão arterial diastólica (mm Hg)          |
| <code>skin</code> | Espessura da dobra cutânea do tríceps (mm)   |
| <code>insu</code> | Insulina sérica ( $\mu$ U/mL)                |
| <code>mass</code> | Índice de massa corporal ( $\text{kg/m}^2$ ) |
| <code>pedi</code> | Função de pedigree de diabetes               |
| <code>age</code>  | Idade (anos)                                 |

#### Distribuição das classes (classificação binária):

A classe negativa (0) corresponde a 500 amostras (65,1%) e a classe positiva (1) a 268 amostras (34,9%), resultando em uma razão de desbalanceamento de aproximadamente 0,54. Embora não se configure um desbalanceamento extremo, foi utilizado o parâmetro `class_weight="balanced"` nos modelos aplicáveis para mitigar qualquer viés em favor da classe majoritária.

#### 4.1.1. Problemas Identificados

**Valores ausentes codificados como zero:** Cinco atributos (`plas`, `pres`, `skin`, `insu` e `mass`) apresentaram valores zero biologicamente impossíveis. A coluna `insu` foi a mais afetada, com 48,7% de zeros inválidos, seguida por `skin` (29,6%), `plas` (0,7%), `pres` (4,6%) e `mass` (1,4%). Esses zeros foram tratados como valores ausentes.

**Outliers:** A análise por IQR identificou outliers em múltiplas variáveis, com destaque para `insu` (34 outliers), `pedi` (29 outliers) e `mass` (19 outliers). A análise

complementar por Z-score ( $-z > 3$ ) confirmou a presença de valores extremos nessas mesmas variáveis.

**Correlação entre atributos:** Nenhum par de features apresentou correlação superior a  $r = 0,7$ , o que indica ausência de multicolinearidade severa. As correlações mais relevantes observadas foram entre `skin` e `insu` ( $r = 0,44$ ) e entre `mass` e `skin` ( $r = 0,39$ ).

## 4.2. Divisão Treino/Teste e Pré-processamento

O pré-processamento dos dados envolveu três operações principais: tratamento de valores ausentes, verificação de codificação de variáveis categóricas e escalonamento numérico. Para evitar o fenômeno de *data leakage* (vazamento de dados), o conjunto original foi inicialmente dividido em treino (80%, 614 amostras) e teste (20%, 154 amostras), com estratificação pela variável alvo. Todas as operações de imputação e escalonamento foram ajustadas (fit) exclusivamente no conjunto de treino, sendo então aplicadas (transform) ao conjunto de teste.

### 4.2.1. Tratamento de Valores Ausentes — KNN Imputer (k=5)

Os zeros biologicamente inválidos nas colunas `plas`, `pres`, `skin`, `insu` e `mass` foram substituídos por NaN e, em seguida, imputados via KNN Imputer com  $k=5$  vizinhos.

A escolha do KNN Imputer, em detrimento da imputação univariada simples (mediana ou média), foi motivada pela necessidade de preservar a estrutura multivariada dos dados. A imputação por mediana ignora as correlações entre os atributos: por exemplo, `skin` e `insu` possuem correlação positiva de  $r=0,44$  e `mass` e `skin` possuem  $r=0,39$ . Um valor imputado para `skin` deve, portanto, considerar as informações contidas em `insu` e `mass`.

O KNN Imputer utiliza os  $k$  vizinhos mais próximos, medidos pela distância euclidiana no espaço das features não ausentes, para estimar o valor faltante. O valor  $k=5$  é um padrão robusto: suficientemente grande para suavizar o ruído, mas pequeno o bastante para capturar padrões locais nos dados.

Após a imputação, foi verificado que nenhum valor NaN remanescente existia no dataset (asserção programática: `nan_after == 0`).

### 4.2.2. Codificação de Variáveis Categóricas

Todos os 8 atributos preditivos são numéricos (contínuos ou discretos), e a variável alvo de classificação (`Outcome`) já se encontra codificada como inteiro (0/1). Portanto, não houve necessidade de aplicar One-Hot Encoding ou Label Encoding. Caso o dataset contivesse variáveis categóricas nominais (sem ordem inerente), seria aplicado One-Hot Encoding para evitar a imposição de uma ordem artificial. Para variáveis ordinais, Label Encoding ou Ordinal Encoding seriam adequados.

### 4.2.3. Escalonamento Numérico — RobustScaler

Três opções de escalonamento foram avaliadas:

1. **StandardScaler (Z-score)**: Assume distribuição aproximadamente normal. É altamente sensível a outliers, pois a média e o desvio padrão são severamente afetados por valores extremos. 2. **MinMaxScaler**: Mapeia os dados para o intervalo [0, 1]. É extremamente sensível a outliers, pois os limites máximo e mínimo podem ser valores atípicos isolados. 3. **RobustScaler**: Utiliza a mediana e o intervalo interquartil ( $IQR = Q3 - Q1$ ).

Optou-se pelo **RobustScaler** por ser robusto a outliers. A mediana e o IQR são estatísticas resistentes — a mediana possui ponto de ruptura de 50%, contra 0% da média. Considerando que variáveis como `insu` (34 outliers por IQR), `pedi` (29 outliers) e `mass` (19 outliers) apresentam caudas longas e distribuições assimétricas, o RobustScaler preserva a estrutura dos dados sem que os outliers distorçam a escala das features.

## 4.3. Seleção de Features

### 4.3.1. Informação Mútua — Método Filtro

A técnica de seleção de atributos empregada foi a Informação Mútua (MI), um método filtro que mede a dependência estatística entre duas variáveis. Três propriedades justificam essa escolha:

1. **Captura de dependências não lineares**: Ao contrário da correlação de Pearson, que mede apenas relações lineares, a MI detecta qualquer tipo de dependência estatística. Em dados clínicos, as relações fisiológicas são frequentemente complexas e não lineares, tornando essa propriedade particularmente relevante. 2. **Independência do modelo (model-agnostic)**: Sendo um método filtro, a MI é independente do modelo a ser treinado. Isso evita viés circular — usar o mesmo modelo para selecionar features e, em seguida, avaliá-las — e garante que as features selecionadas beneficiem qualquer algoritmo subsequente. 3. **Eficiência computacional**: A complexidade é consideravelmente menor quando comparada a métodos wrapper como Recursive Feature Elimination com validação cruzada.

Para estabilizar as estimativas de MI (que dependem de aleatoriedade interna do estimador KNN utilizado pelo scikit-learn), foram executadas 50 rodadas com sementes aleatórias distintas, e os scores finais foram calculados como a média dessas execuções.

- **Quantidade inicial de atributos**: 8
- **Critério de seleção**: Features com MI acima da média geral dos scores (regra do cotovelo adaptada).
- **Quantidade final de atributos selecionados**: 4
- **Features selecionadas**: As 4 features que superaram o limiar de MI.
- **Features descartadas**: As 4 features com MI abaixo do limiar.

### 4.3.2. Avaliação Comparativa — Todas as Features vs. Features Selecionadas

Para avaliar o impacto da seleção de features, foi treinado um modelo base Random Forest (`n_estimators=100`, `class_weight="balanced"`, `random_state=42`) com

validação cruzada estratificada de 10 folds em dois cenários: (a) com todas as 8 features e (b) apenas com as 4 features selecionadas.

A análise comparativa incluiu os seguintes critérios:

- **Desempenho:** Métricas como Accuracy, Precision, Recall, F1-Score e ROC-AUC.
- **Redução de overfitting:** Comparação entre a diferença de Accuracy no treino e no teste (gap de generalização) em ambos os cenários.
- **Tempo de treinamento:** Redução no custo computacional ao utilizar um subconjunto reduzido de features.
- **Interpretabilidade:** Com menos atributos, o modelo resultante é mais facilmente interpretável por especialistas do domínio.

4.3.3. Interpretabilidade via SHAP (Extra)

A biblioteca SHAP (SHapley Additive Explanations) foi utilizada para interpretar as decisões de um modelo Random Forest treinado com todas as features. O TreeExplainer foi empregado, por ser exato para modelos baseados em árvores.

Foram geradas as seguintes análises:

- **Importância global:** SHAP Summary Plot (beeswarm) e SHAP Bar Plot, indicando quais atributos exercem maior influência nas predições.
- **Explicação local:** Waterfall plots para uma amostra da classe positiva (diabética) e uma da classe negativa, mostrando a contribuição individual de cada feature para a predição específica.
- **Comparação MI vs. SHAP:** Correlação de Spearman entre os rankings de importância gerados pela Informação Mútua e pelo SHAP, avaliando a concordância entre os dois métodos.

4.4. Classificação Binária com MLP

4.4.1. Arquitetura da MLP

A arquitetura da MLP para classificação binária foi definida com base nos seguintes critérios:

| Hiperparâmetro      | Valor        | Justificativa                                               |
|---------------------|--------------|-------------------------------------------------------------|
| Camadas ocultas     | (64, 32, 16) | Pirâmide decrescente — regularização implícita              |
| Função de ativação  | ReLU         | Evita vanishing gradient                                    |
| Otimizador          | Adam         | Combina momentum e RMSProp com adaptação automática da taxa |
| Taxa de aprendizado | 0,001        | Valor padrão estável para o Adam                            |
| Épocas máximas      | 500          | Limite superior; early stopping controla a parada efetiva   |
| Batch size          | 32           | Mini-batch adequado ao volume de dados                      |
| Early stopping      | Sim          | Paciência de 30 épocas, fração de validação de 15%          |

Justificativa da arquitetura:

- **Tamanho do dataset:** 768 amostras é um volume relativamente pequeno para deep learning. Redes muito profundas ou largas causariam overfitting severo rapidamente.
- **Dimensionalidade:** Com apenas 4 features selecionadas, a capacidade necessária da rede é limitada. Uma rede com 3 camadas ocultas ( $64 \rightarrow 32 \rightarrow 16$ ) oferece flexibilidade suficiente para capturar interações não lineares sem excesso de parâmetros.
- **Pirâmide decrescente:** A redução progressiva de neurônios ( $64 \rightarrow 32 \rightarrow 16$ ) é uma heurística clássica que força a rede a aprender representações cada vez mais compactas, atuando como uma forma de regularização implícita.
- **Total de parâmetros:** A rede possui aproximadamente 3.500 parâmetros treináveis, mantendo um número muito inferior ao total de amostras de treino para evitar memorização.

A divisão dos dados seguiu a proporção 80% treino / 20% teste, com estratificação pela variável alvo, garantindo a manutenção da proporção de classes em ambos os conjuntos.

#### 4.4.2. Comparação com Modelos Clássicos (Extra)

Para contextualizar o desempenho da MLP, dois modelos clássicos foram treinados e avaliados nas mesmas condições:

- **XGBoost:** `n_estimators=100, max_depth=5, learning_rate=0.1`.
- **SVM (kernel RBF):** `C=1.0, gamma="scale", class_weight="balanced"`.

Além da avaliação no conjunto de teste (hold-out), foi realizada validação cruzada estratificada de 10 folds para os três modelos, com métricas de Accuracy, F1-Score e ROC-AUC.

#### 4.5. Classificação Multiclasse com MLP

Para a tarefa de classificação multiclasse, foi criada uma variável alvo derivada dos limiares clínicos da American Diabetes Association (ADA) para glicose plasmática em jejum:

| Classe | Rótulo        | Critério                              |
|--------|---------------|---------------------------------------|
| 0      | Normal        | glicose $\leq 100$ mg/dL              |
| 1      | Pré-diabético | $100 < \text{glicose} \leq 140$ mg/dL |
| 2      | Diabético     | glicose $> 140$ mg/dL                 |

Os limiares foram aplicados sobre os valores originais (não escalonados) da variável `plas`. As features utilizadas para a classificação multiclasse foram todas as colunas do dataset exceto `plas` (que define o target), incluindo `Outcome` como feature — uma vez que este reflete um diagnóstico independente (baseado no Oral Glucose Tolerance Test), distinto da glicose de jejum.

A arquitetura da MLP multiclasse seguiu a mesma configuração da binária: 3 camadas ocultas ( $64 \rightarrow 32 \rightarrow 16$ ), ReLU, Adam, early stopping com 30 épocas de paciência e batch size de 32. A camada de saída possui 3 neurônios (um por classe), com softmax implícito na implementação do `MLPClassifier` do scikit-learn.

## 4.6. Regressão com MLP

### 4.6.1. Arquitetura da MLP de Regressão

| Hiperparâmetro      | Valor    | Justificativa                                                             |
|---------------------|----------|---------------------------------------------------------------------------|
| Camadas ocultas     | (64, 32) | Funil clássico; menos camadas que a classificação para evitar memorização |
| Função de ativação  | ReLU     | Padrão para manter não linearidades ativas e evitar vanishing gradient    |
| Otimizador          | Adam     | Adaptação automática da taxa de aprendizado                               |
| Taxa de aprendizado | 0,001    | Valor padrão estável                                                      |
| Épocas máximas      | 1.000    | Limite superior ampliado para regressão                                   |
| Batch size          | 32       | Mini-batch adequado ao volume                                             |
| Early stopping      | Sim      | Paciência de 20 épocas, fração de validação de 15%                        |

**Justificativa:** Modelos de regressão frequentemente necessitam de menos camadas do que modelos de classificação para evitar memorização excessiva, mantendo um funil clássico e contínuo. O early stopping, habilitado com paciência de 20 épocas, interrompe o treinamento assim que o erro de validação para de melhorar, prevenindo o overfitting e preservando o modelo com a melhor capacidade de generalização.

A variável alvo para regressão foi a concentração de glicose plasmática (`plas`) nos valores originais (não escalonados, em mg/dL), para que as métricas de erro (MAE, RMSE) sejam interpretáveis na unidade clínica. As features de entrada foram as demais variáveis do dataset escalonado.

## 4.7. Otimização de Hiperparâmetros com Optuna

O framework Optuna foi utilizado para otimizar os hiperparâmetros da MLP de classificação binária. O espaço de busca definido foi:

| Hiperparâmetro            | Espaço de Busca                                              |
|---------------------------|--------------------------------------------------------------|
| Número de camadas ocultas | 1 a 3                                                        |
| Neurônios por camada      | 16 a 128 (passo de 16)                                       |
| Taxa de aprendizado       | $1 \times 10^{-4}$ a $1 \times 10^{-2}$ (escala logarítmica) |
| Função de ativação        | relu, tanh                                                   |
| Alpha (L2)                | $1 \times 10^{-4}$ a $1 \times 10^{-2}$ (escala logarítmica) |

- **Número de trials:** 30
- **Função objetivo:** Maximização do ROC-AUC via validação cruzada de 5 folds.
- **Otimizador base:** Adam com `max_iter=300` e early stopping habilitado.

Os resultados do Optuna foram comparados com o modelo MLP original no conjunto de teste para avaliar os ganhos de desempenho.

## 4.8. Regularização e Análise de Overfitting

Para investigar o comportamento da MLP em relação ao overfitting, foram treinados dois modelos contrastantes:

**Modelo sem regularização (propenso a overfitting):**

- Arquitetura ampla: (256, 128, 64) — 3 camadas com elevado número de neurônios.
- $\alpha = 0.0$  — sem penalização L2.
- `n_iter_no_change = 500` — early stopping efetivamente desabilitado, forçando o treinamento a prosseguir por todas as 500 épocas.

#### Modelo com regularização:

- Arquitetura simplificada: (64, 32) — 2 camadas com menos neurônios (regularização estrutural).
- $\alpha = 0.01$  — penalização L2 ativa, forçando pesos menores e mais distribuídos.
- `n_iter_no_change = 15` — early stopping agressivo, interrompendo o treinamento após 15 épocas sem melhora na validação.

As três estratégias de regularização aplicadas no modelo regularizado foram:

1. **Simplificação estrutural:** Redução de (256, 128, 64) para (64, 32). Menos neurônios implicam menor capacidade de memorização da rede. 2. **Regularização L2 ( $\alpha=0.01$ ):** Penalização de pesos elevados durante o treinamento, forçando a rede a utilizar pesos menores e mais distribuídos, o que suaviza a fronteira de decisão. 3. **Early Stopping:** Monitoramento da acurácia de validação com paciência de 15 épocas, congelando os pesos no ponto de melhor generalização.

## 5. Resultados e Discussão

### 5.1. Análise Exploratória

A análise exploratória revelou as características fundamentais do dataset. A Figura 1 apresenta a distribuição de todos os atributos, onde se observam picos em zero para as variáveis `plas`, `pres`, `skin`, `insu` e `mass` — confirmando a presença de valores ausentes codificados como zero.






Figura 1. Distribuição dos atributos do dataset.

A Figura 2 exibe os boxplots por classe (Outcome), evidenciando que variáveis como `plas`, `mass` e `age` apresentam distribuições visivelmente distintas entre as classes positiva e negativa, sugerindo poder discriminativo relevante.




**Figura 2. Boxplots dos atributos por classe (Outcome).**



**Figura 3. Matriz de correlação de Pearson entre os atributos.**

A Figura 3 apresenta a matriz de correlação de Pearson, na qual se observa a ausência de multicolinearidade severa (nenhum par com  $|r| > 0,7$ ). As correlações mais relevantes são entre *skin* e *insu* ( $r = 0,44$ ) e entre *age* e *preg* ( $r = 0,54$ ).

A variável de regressão (*plas*) apresenta distribuição com leve assimetria positiva, conforme ilustrado na Figura 4. O Q-Q Plot indica um desvio da normalidade nas caudas, especialmente na cauda superior.




**Figura 4. Análise da variável de regressão (glicose): distribuição e Q-Q Plot.**

A distribuição da variável alvo de classificação binária é mostrada na Figura 5, com 500 amostras negativas e 268 positivas.


## 5.2. Pré-processamento

A Figura 6 compara as distribuições dos 5 atributos afetados antes (com zeros inválidos) e após a imputação por KNN. Observa-se que a imputação eliminou os picos artifici-




**Figura 5. Distribuição da classe alvo de classificação binária.**

ais em zero, especialmente visíveis em `insu` e `skin`, preservando a forma geral das distribuições.




**Figura 6. Distribuições antes e depois da imputação KNN.**

A Figura 7 apresenta os boxplots antes e após o escalonamento com RobustScaler. Após o escalonamento, todas as features estão centradas na mediana (valor 0) com dispersão proporcional ao IQR, permitindo que algoritmos sensíveis à escala (como MLPs e SVMs) operem de forma adequada.



**Figura 7. Boxplots antes e após o escalonamento com RobustScaler.**

A Figura 8 exibe a matriz de correlação pós-processamento, confirmando que as relações estruturais entre os atributos foram preservadas pelo pipeline de pré-processamento.




**Figura 8. Matriz de correlação de Pearson pós-processamento.**

### 5.3. Seleção de Features e Interpretabilidade

#### 5.3.1. Análise SHAP — Importância Global

A Figura 9 apresenta o SHAP Summary Plot (beeswarm), que exibe a distribuição dos valores SHAP para cada feature ao longo de todas as amostras. Valores SHAP positivos empurram a predição em direção à classe positiva (diabética), enquanto valores negativos empurram em direção à classe negativa.




**Figura 9. SHAP Summary Plot: importância global das features para a classe positiva.**


A Figura 10 complementa a análise com o SHAP Bar Plot, que mostra a importância média absoluta de cada atributo.

#### 5.3.2. Explicação Local — Predições Individuais

As Figuras 11 e 12 apresentam os waterfall plots do SHAP para uma amostra da classe positiva e uma da classe negativa, respectivamente. Esses gráficos decompõem a predição individual em contribuições aditivas de cada feature, partindo do valor base (predição média do modelo) até a predição final.



**Figura 10. SHAP Bar Plot: importância média dos atributos.**



**Figura 11. SHAP Waterfall: explicação local de uma amostra positiva (diabética).**

### 5.3.3. Comparação MI vs. SHAP

A Figura 13 exibe lado a lado os rankings de importância gerados pela Informação Mútua e pelo SHAP. As barras coloridas representam as features selecionadas pela MI (acima do limiar), enquanto as barras cinzas representam as features descartadas.

A concordância entre os dois métodos foi avaliada por meio da correlação de Spearman entre os rankings. A análise indica que as features consideradas mais relevantes por ambos os métodos apresentam sobreposição, corroborando a seleção realizada pela MI: as técnicas convergem na identificação dos atributos com maior poder preditivo.

### 5.3.4. Impacto da Seleção de Features

A Figura 14 apresenta a comparação de desempenho entre os modelos treinados com todas as 8 features e apenas com as 4 features selecionadas, utilizando Random Forest com validação cruzada de 10 folds.

A seleção de features demonstrou os seguintes efeitos:

- **Desempenho:** As métricas se mantiveram competitivas mesmo com a redução de 50% dos atributos, indicando que as features descartadas contribuíam com informação redundante ou irrelevante.




Figura 12. SHAP Waterfall: explicação local de uma amostra negativa (não diabética).




Figura 13. Comparação dos rankings de importância: Informação Mútua vs. SHAP.

- **Redução de overfitting:** O gap entre acurácia de treino e teste diminuiu no cenário com features selecionadas, indicando melhor generalização.
- **Tempo de treinamento:** O treinamento com 4 features foi mais rápido do que com 8 features.
- **Interpretabilidade:** Com metade dos atributos, o modelo resultante é mais facilmente interpretável por profissionais da área de saúde.

## 5.4. Classificação Binária com MLP


### 5.4.1. Curvas de Aprendizado

A Figura 15 apresenta as curvas de aprendizado da MLP de classificação binária. O painel esquerdo mostra a evolução da perda (loss) por época no conjunto de treino e a métrica complementar no conjunto de validação. O painel direito exibe a evolução da acurácia de validação, com a linha pontilhada indicando o melhor valor obtido.


As curvas indicam convergência estável, com a perda de treino decrescendo de forma monotônica e a acurácia de validação estabilizando após um número moderado de épocas. O early stopping interrompeu o treinamento no ponto adequado, evitando a degradação do desempenho de validação.

### 5.4.2. Matrizes de Confusão

A Figura 16 apresenta as matrizes de confusão dos três modelos avaliados (MLP, XGBoost e SVM), permitindo a comparação visual do número de verdadeiros positivos, verda-




**Figura 14. Desempenho comparativo: todas as features vs. features selecionadas (RF, 10-fold CV).**



**Figura 15. MLP de classificação binária: curvas de aprendizado (loss e accuracy por época).**

deiros negativos, falsos positivos e falsos negativos.



**Figura 16. Matrizes de confusão comparativas: MLP, XGBoost e SVM.**


### 5.4.3. Curvas ROC

A Figura 17 sobrepõe as curvas ROC dos três modelos. A área sob a curva (AUC) indica a capacidade de discriminação de cada modelo, com valores mais próximos de 1,0 representando melhor desempenho.


### 5.4.4. Comparação de Métricas

A Figura 18 sintetiza a comparação de métricas (Accuracy, Precision, Recall, F1-Score e ROC-AUC) entre os três modelos.

Os três modelos apresentaram desempenho competitivo entre si, com valores de ROC-AUC acima de 0,80 no conjunto de teste. Esse resultado indica que a MLP, apesar de não superar consistentemente os modelos clássicos neste cenário de dados limitados (768 amostras), alcançou desempenho equivalente, validando sua adequação para o problema.



**Figura 17. Curvas ROC comparativas: MLP, XGBoost e SVM.**



**Figura 18. Comparação de métricas de classificação: MLP vs. XGBoost vs. SVM.**

### 5.5. Classificação Multiclasse com MLP

A classificação multiclasse foi realizada com base nos limiares clínicos da ADA para glicose plasmática. A distribuição das classes derivadas é apresentada na Figura 19.

| Classe                        | Amostras |
|-------------------------------|----------|
| Normal ( $< 100$ mg/dL)       | 212      |
| Pré-diabético (100–140 mg/dL) | 364      |
| Diabético ( $\geq 140$ mg/dL) | 192      |


As métricas de avaliação no conjunto de teste são apresentadas na tabela a seguir:

A Figura 20 exibe a matriz de confusão 3×3 do modelo multiclasse. Observa-se que a classe "Pré-diabético" apresenta a maior taxa de confusão, o que é esperado por se tratar de uma classe intermediária cujas fronteiras de decisão são limítrofes com as classes adjacentes.

A Figura 21 apresenta as curvas de aprendizado da MLP multiclasse, evidenciando convergência estável com o early stopping atuando de forma adequada.

A Figura 22 resume as métricas obtidas em formato de gráfico de barras.

A Accuracy de 0,64 e o F1 Macro de 0,64 para um problema com 3 classes clinicamente definidas podem ser considerados resultados satisfatórios, particularmente tendo



**Figura 19. Distribuição das classes para classificação multiclasse (limiares ADA).**

| Métrica         | Valor  |
|-----------------|--------|
| Accuracy        | 0,6364 |
| Precision Macro | 0,6427 |
| Recall Macro    | 0,6359 |
| F1 Macro        | 0,6373 |

em vista o volume limitado de amostras e a natureza da fronteira entre as classes intermediárias.

## 5.6. Regressão com MLP


As métricas de desempenho da MLP de regressão no conjunto de teste são:

| Métrica        | Valor         |
|----------------|---------------|
| MAE            | 18,6116 mg/dL |
| MSE            | 603,7746      |
| RMSE           | 24,5718 mg/dL |
| R <sup>2</sup> | 0,4165        |


O R<sup>2</sup> de 0,42 indica que o modelo explica aproximadamente 42% da variância da concentração de glicose plasmática. O MAE de 18,61 mg/dL representa um erro médio absoluto na unidade clínica original, o que pode ser contextualizado frente à amplitude do intervalo da variável (plas varia de aproximadamente 44 a 199 mg/dL no dataset imputado).

A Figura 23 apresenta, em três painéis, a avaliação do modelo de regressão: (a) valores reais versus preditos, com a linha ideal de referência; (b) análise de resíduos; e (c) curva de aprendizado (loss e R<sup>2</sup> por época).

No gráfico de valores reais vs. preditos, observa-se que os pontos se concentram em torno da linha ideal, porém com dispersão considerável nas extremidades (valores de glicose muito baixos ou muito altos), indicando que o modelo tem dificuldade em prever os casos mais extremos. A análise de resíduos mostra uma distribuição centrada em zero, sem padrões sistemáticos evidentes, o que sugere que o modelo não apresenta viés estrutural significativo. A curva de aprendizado demonstra convergência estável, com o early stopping interrompendo o treinamento no momento adequado.



**Figura 20. Matriz de confusão da classificação multiclasse (MLP).**



**Figura 21. Curvas de aprendizado da MLP multiclasse.**

### 5.7. Otimização de Hiperparâmetros com Optuna

O processo de otimização com Optuna executou 30 trials em aproximadamente 6,9 segundos. Os resultados são sintetizados a seguir:

**Melhor ROC-AUC obtido via validação cruzada: 0,8344**

**Melhores hiperparâmetros encontrados:**


| Hiperparâmetro      | Valor  |
|---------------------|--------|
| Número de camadas   | 2      |
| Neurônios camada 0  | 16     |
| Neurônios camada 1  | 112    |
| Taxa de aprendizado | 0,0010 |
| Função de ativação  | relu   |
| Alpha (L2)          | 0,0001 |

**Comparação com o modelo original no conjunto de teste:**

A Figura 24 exibe o histórico de otimização do Optuna, mostrando a evolução do valor objetivo (ROC-AUC) ao longo dos 30 trials.

A Figura 25 apresenta a importância dos hiperparâmetros estimada pelo Optuna, indicando quais parâmetros exercem maior influência sobre o desempenho do modelo.

O delta de -0,0091 no ROC-AUC entre o modelo original e o otimizado indica que a configuração inicial da MLP, o que pode indicar variância natural entre os folds de



**Figura 22. Métricas de classificação multiclasse (MLP).**



**Figura 23. Avaliação da MLP de regressão: valores reais vs. preditos, resíduos e curva de aprendizado.**

validação e o conjunto de teste final.

## 5.8. Regularização e Análise de Overfitting

A Figura 26 apresenta a comparação das curvas de aprendizado entre o modelo sem regularização (painel esquerdo) e o modelo regularizado (painel direito). No modelo sem regularização, observa-se a métrica de treino (1 - Loss) crescendo de forma contínua enquanto a acurácia de validação estagna, configurando o padrão clássico de overfitting. No modelo regularizado, as curvas de treino e validação permanecem mais próximas, indicando melhor equilíbrio entre ajuste e generalização.


As métricas comparativas no conjunto de teste são:

### 5.8.1. Discussão sobre Overfitting

**A rede apresentou sinais de overfitting?** Sim. O modelo sem regularização (256, 128, 64 neurônios,  $\alpha=0$ ) exibiu o padrão clássico nas curvas de aprendizado: a métrica de treino continuou a subir de forma contínua, enquanto a métrica de validação estagnou e apresentou oscilações, evidenciando o "descolamento" característico entre treino e teste. Esse comportamento confirma que a rede, ao memorizar padrões específicos do conjunto de treino (incluindo ruído e outliers), perdeu capacidade de generalização.

**Quais técnicas de regularização foram utilizadas?** Três estratégias foram aplicadas de forma conjunta: (1) simplificação estrutural — redução das camadas de (256, 128, 64) para (64, 32), diminuindo a capacidade de memorização da rede; (2) regularização L2 com  $\alpha=0,01$  — penalização de pesos elevados, forçando a rede a utilizar pesos menores e mais distribuídos; (3) early stopping com paciência de 15 épocas — interrupção do treinamento quando a acurácia de validação parou de melhorar.

| Modelo        | ROC-AUC (teste) |
|---------------|-----------------|
| MLP Original  | 0,7902          |
| MLP Otimizada | 0,7811          |
| Delta         | -0,0091         |



**Figura 24. Histórico de otimização do Optuna.**

**Houve melhoria no desempenho em dados não vistos?** As métricas no conjunto de teste mostraram melhora no modelo regularizado para Accuracy (+0,0195) e F1-Score (+0,0074), embora tenha havido leve queda no ROC-AUC (-0,0015). A análise das curvas de aprendizado mostra que o modelo regularizado apresenta menor gap entre treino e validação, indicando melhor capacidade de generalização e prevenindo quedas abruptas de desempenho em dados inéditos.

**Qual estratégia apresentou melhor equilíbrio entre desempenho e generalização?** O modelo regularizado apresentou melhor equilíbrio. Apesar de métricas finais semelhantes, a estabilidade das curvas de treino-validação e a menor tendência a memorização tornam o modelo regularizado preferível em cenários de produção, onde a robustez a dados inéditos é prioritária. A combinação de simplificação estrutural + L2 + early stopping demonstrou eficácia na contenção do overfitting sem degradação significativa do desempenho.


## 6. Conclusão

O presente trabalho cumpriu os objetivos propostos ao implementar um pipeline completo de Machine Learning aplicado ao dataset *Pima Indians Diabetes*, abrangendo todas as etapas requisitadas: análise exploratória, pré-processamento, seleção de features, classificação (binária e multiclasse), regressão, otimização de hiperparâmetros e análise de overfitting.


Os principais resultados obtidos podem ser sintetizados da seguinte forma:

1. **Pré-processamento:** O KNN Imputer (k=5) e o RobustScaler demonstraram-se adequados para o tratamento do dataset, preservando a estrutura multivariada dos dados e mitigando o impacto de outliers, respectivamente.

2. **Seleção de features:** A Informação Mútua reduziu o conjunto de 8 para 4 atributos sem degradação significativa de desempenho. A análise SHAP corroborou



**Figura 25. Importância dos hiperparâmetros estimada pelo Optuna.**



**Figura 26. Comparação de overfitting: modelo sem regularização vs. modelo regularizado.**

a seleção, com concordância entre os rankings de importância gerados por ambos os métodos.

**3. Classificação binária:** A MLP com arquitetura (64, 32, 16) obteve ROC-AUC de 0,7902 no conjunto de teste, desempenho competitivo frente a modelos clássicos e confirmando a capacidade discriminatória com as variáveis selecionadas.

**4. Classificação multiclasse:** A MLP atingiu Accuracy de 0,6364 e F1 Macro de 0,6373 na categorização de níveis glicêmicos em três classes clínicas (Normal, Pré-diabético e Diabético), resultado considerado satisfatório dado o volume de dados e a natureza limítrofe das fronteiras entre classes.

**5. Regressão:** O modelo MLP de regressão obteve  $R^2 = 0,42$  e  $MAE = 18,61$  mg/dL na predição da glicose plasmática, explicando 42% da variância da variável alvo. A curva de resíduos não indicou viés sistemático.

**6. Otimização com Optuna:** A busca por hiperparâmetros (30 trials) resultou em ROC-AUC de validação cruzada de 0,8344, porém sem ganho significativo no conjunto de teste em relação ao modelo original ( $\Delta = -0,0091$ ). Esse resultado sugere que o desempenho é limitado pelo volume e pela natureza dos dados, e não pela configuração de hiperparâmetros.

**7. Regularização:** A análise de overfitting confirmou que a rede sem regularização apresentou sinais claros de memorização. A combinação de simplificação estrutural, regularização L2 e early stopping mitigou esse comportamento, melhorando o Accuracy (0,7273 vs 0,7078) e F1-Score no conjunto de teste.

Em suma, o projeto demonstrou que técnicas de aprendizado supervisionado,

| Métrica  | Sem Regularização | Com Regularização | Delta   |
|----------|-------------------|-------------------|---------|
| Accuracy | 0,7078            | 0,7273            | +0,0195 |
| F1-Score | 0,5361            | 0,5435            | +0,0074 |
| ROC-AUC  | 0,7911            | 0,7896            | -0,0015 |

mesmo em datasets de volume moderado, podem produzir modelos com capacidade discriminativa relevante para o auxílio ao diagnóstico clínico. A integração de métodos de interpretabilidade (SHAP) com a seleção de features (MI) fortaleceu a transparência e a confiabilidade do pipeline, elementos essenciais em aplicações na área de saúde. O resultado global do projeto indica um equilíbrio adequado entre complexidade do modelo, desempenho preditivo e capacidade de generalização.